自动并行-并行划分

嘉宾： 王俊祥

并行划分

1、背景

2、数据并行

3、模型并行

4、混合并行

5、总结

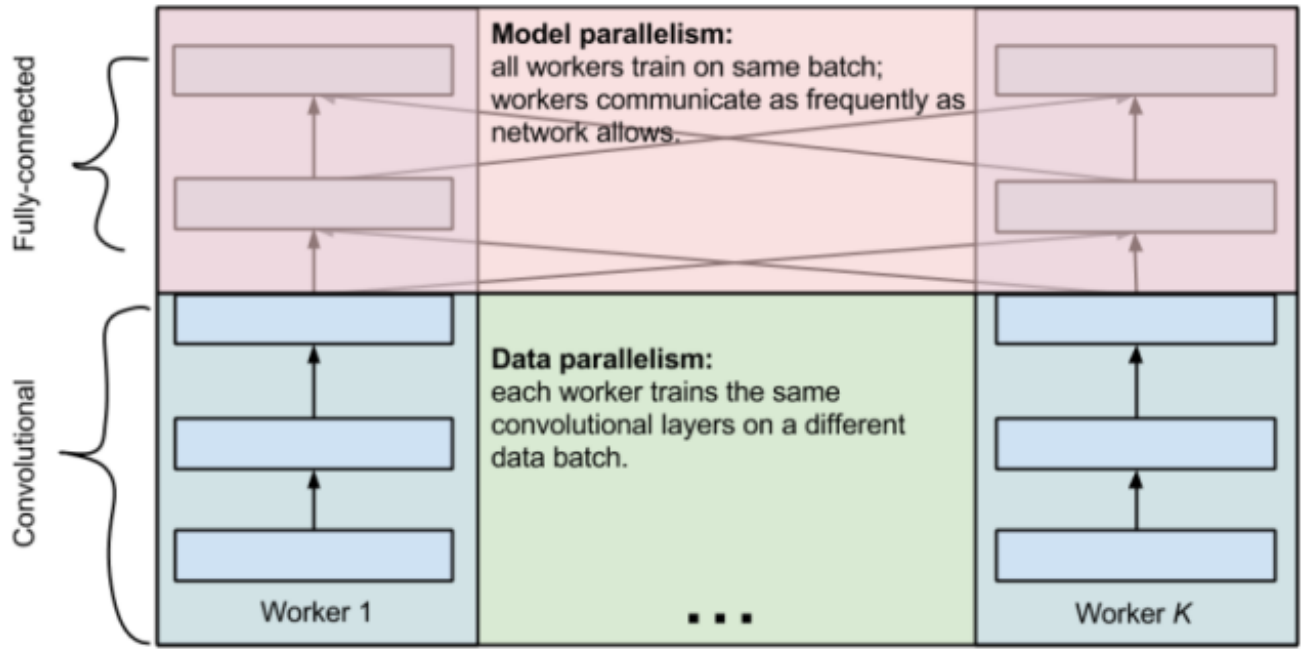

1、背景

数据与模型规模的扩大

单机瓶颈

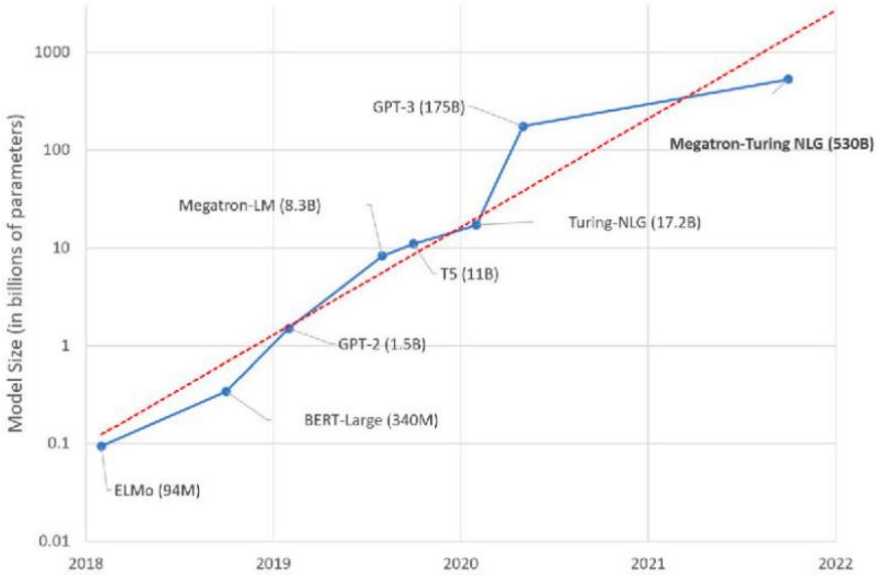

2、数据并行

提升训练速度

数据并行划分的是数据，把整个样本空间划分为多个子集，然后分发给不同的工作节点。每个工作节点拥有完整的神经网络模型，每次训练仅将一批数据输入模型，进行前向传播、计算误差、反向传播，最后进行参数更

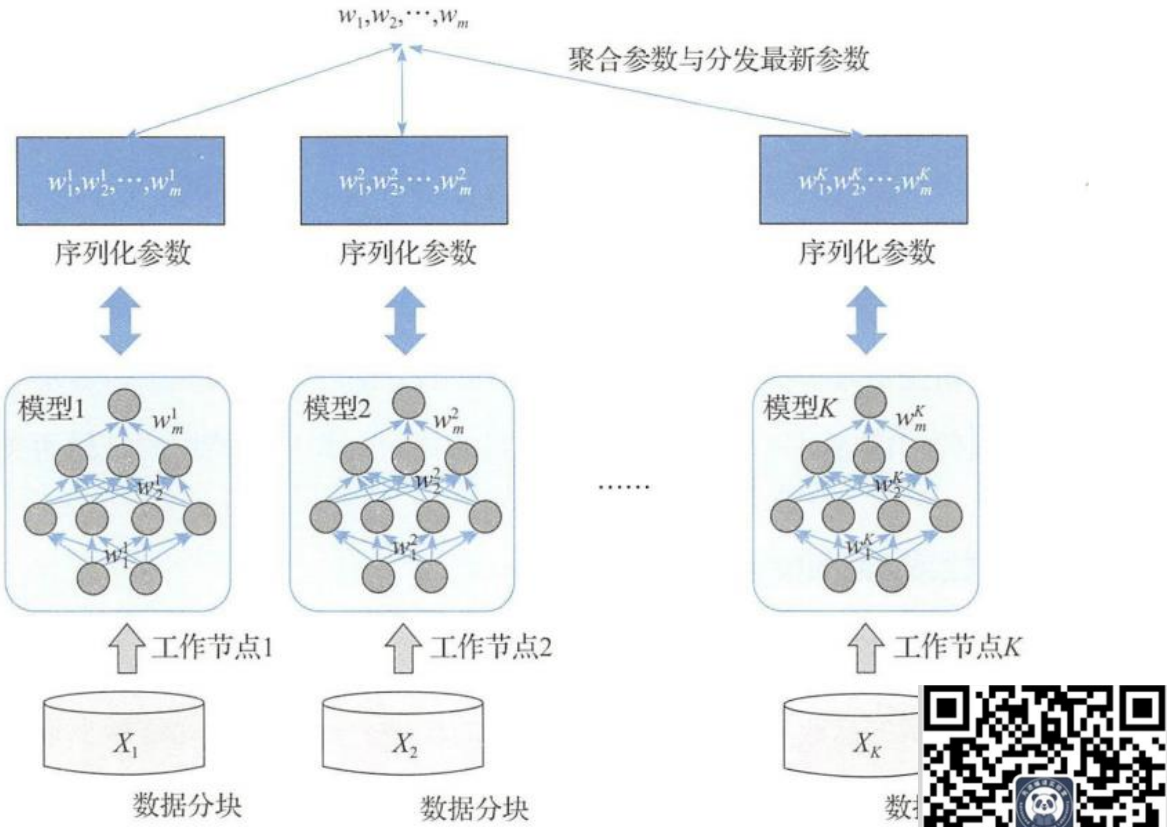

先进编译实验室
Advanced Compiler

2、数据并行

1、DP

2、DDP

3、FSDP

数据并行

2.1、DP

- 单进程，多线程，只能适用于1台机器的情况（单机多卡）
- 不能结合模型并行的方法
- 使用Parameter Server (PS, 参数服务器) 架构，默认GPU 0 为主GPU。

- 负载不均衡
- 通信[illegible]着 GPU 数量线性增[illegible]

先进编译实验室
Advanced Compiler

Data Parallel

One GPU (0) acts as the master GPU and coordinates data transfer.

Implemented in PyTorch data_parallel module

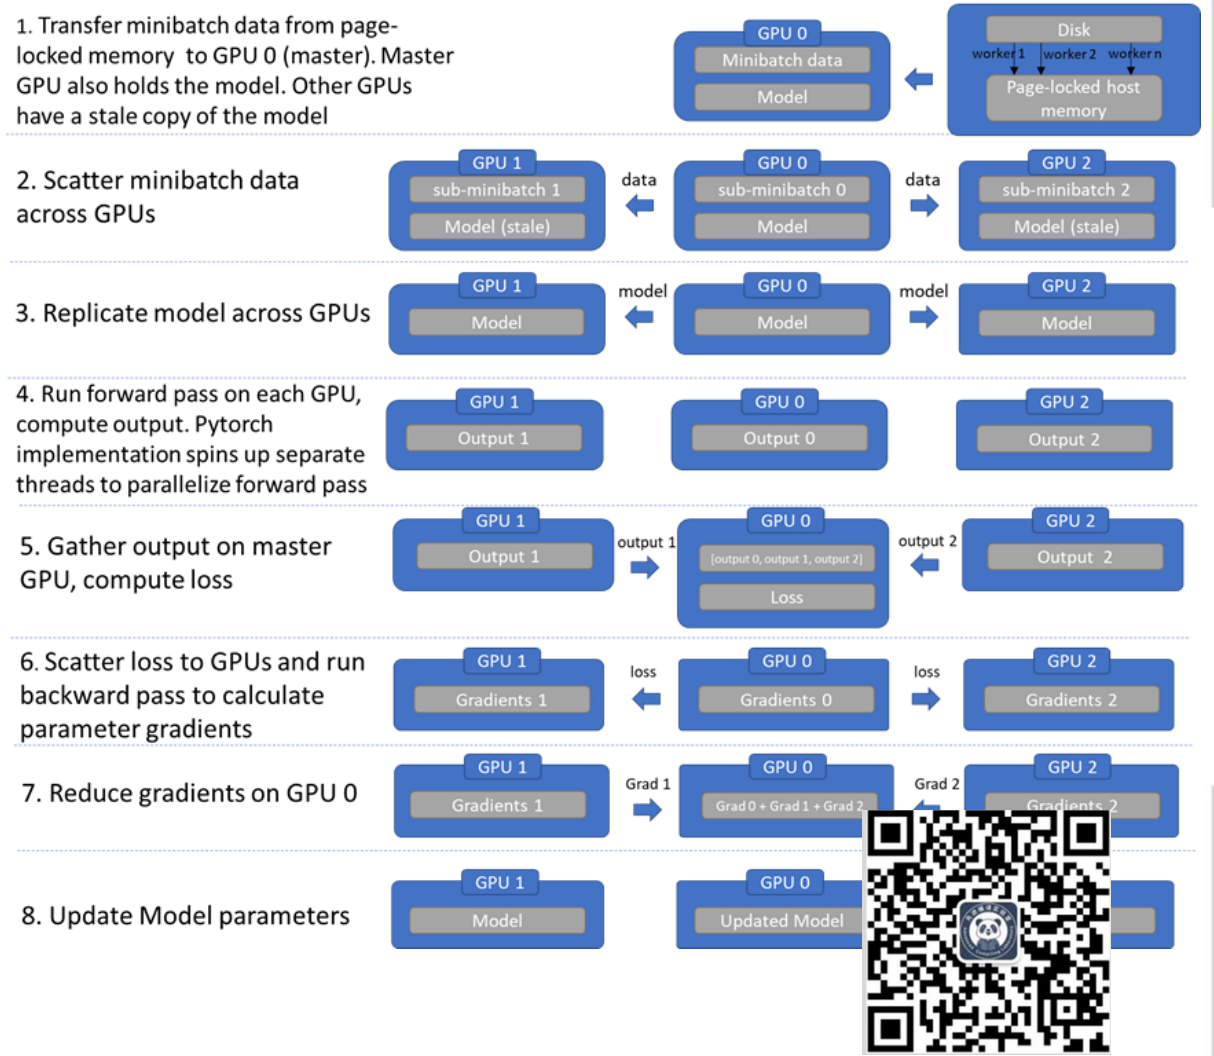

2.2、DDP

- 多进程，可以适用于多台机器（多机多卡，也可用于单机多卡）
- 可以结合模型并行
- All-Reduce模式，只传输梯度

- 占用GPU内存比实际需要的多

先进编译实验室
Advanced Compiler

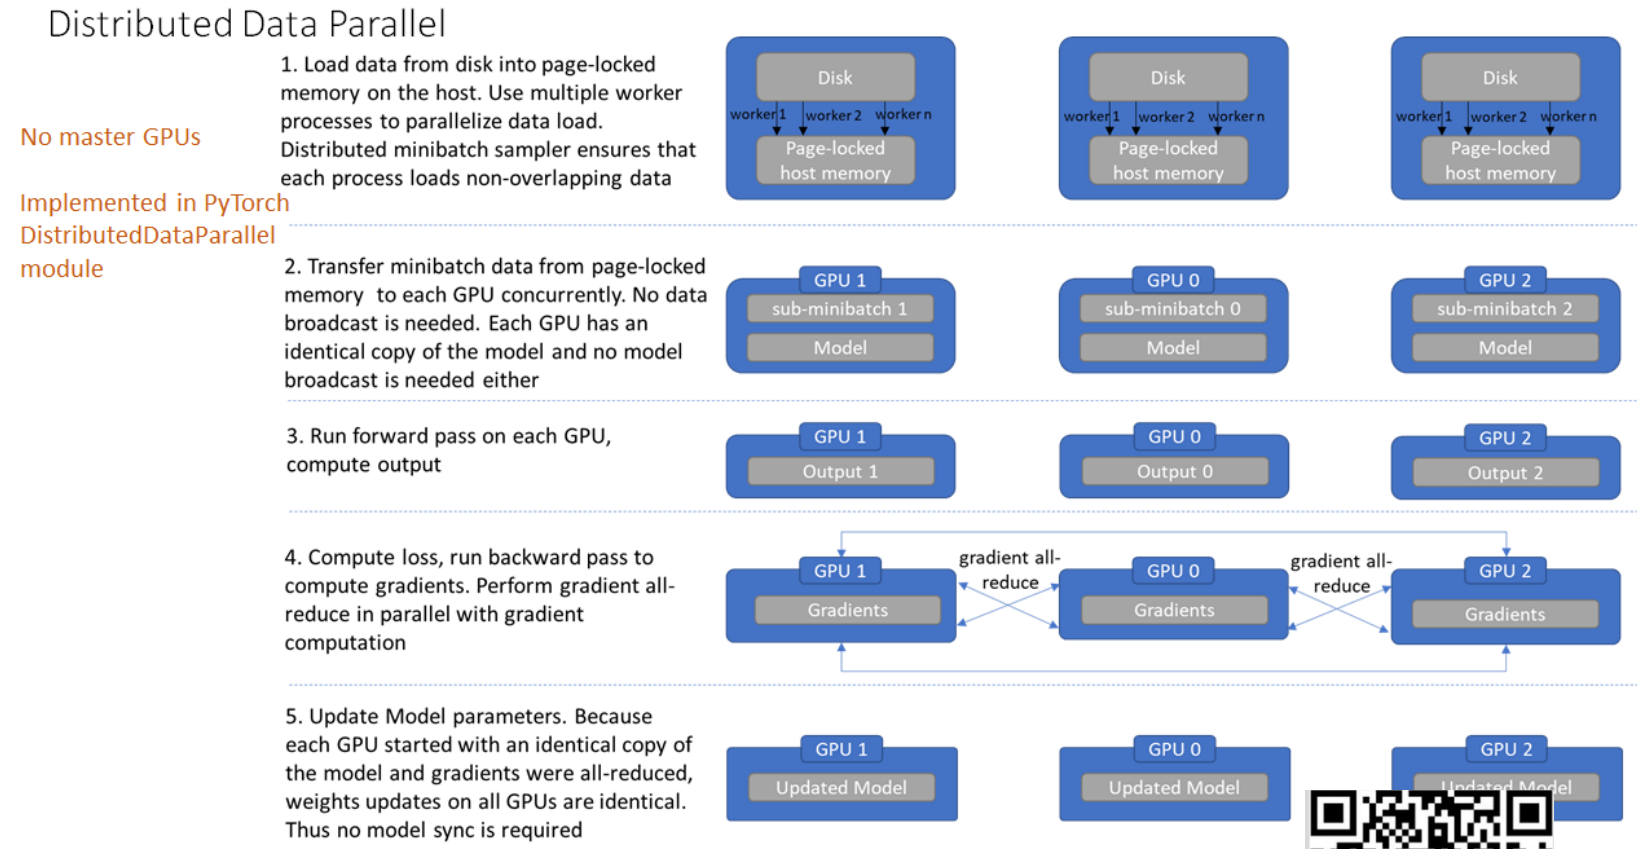

2.3、FSDP

Fully Sharded Data Parallel

FSDP shards all of **model's parameters, gradients and optimizer states** across data-parallel workers and can optionally **offload the sharded model parameters to CPUs.**

把DDP之中的All Reduce操作分解为独立的 Reduce-Scatter 和 All-gather 操作。

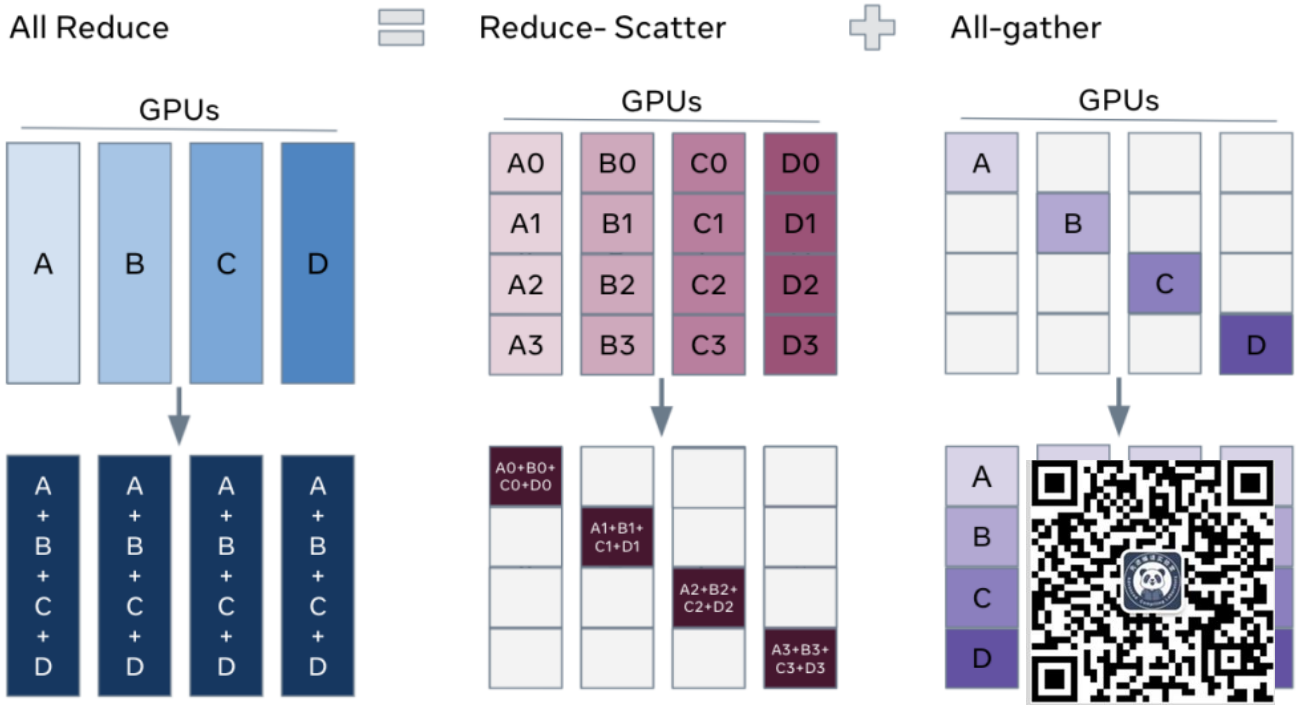

先进编译实验室
Advanced Compiler

2.3、FSDP

Fully Sharded Data Parallel

FSDP shards all of **model's parameters, gradients and optimizer states** across data-parallel workers and can optionally **offload the sharded model parameters to CPUs.**

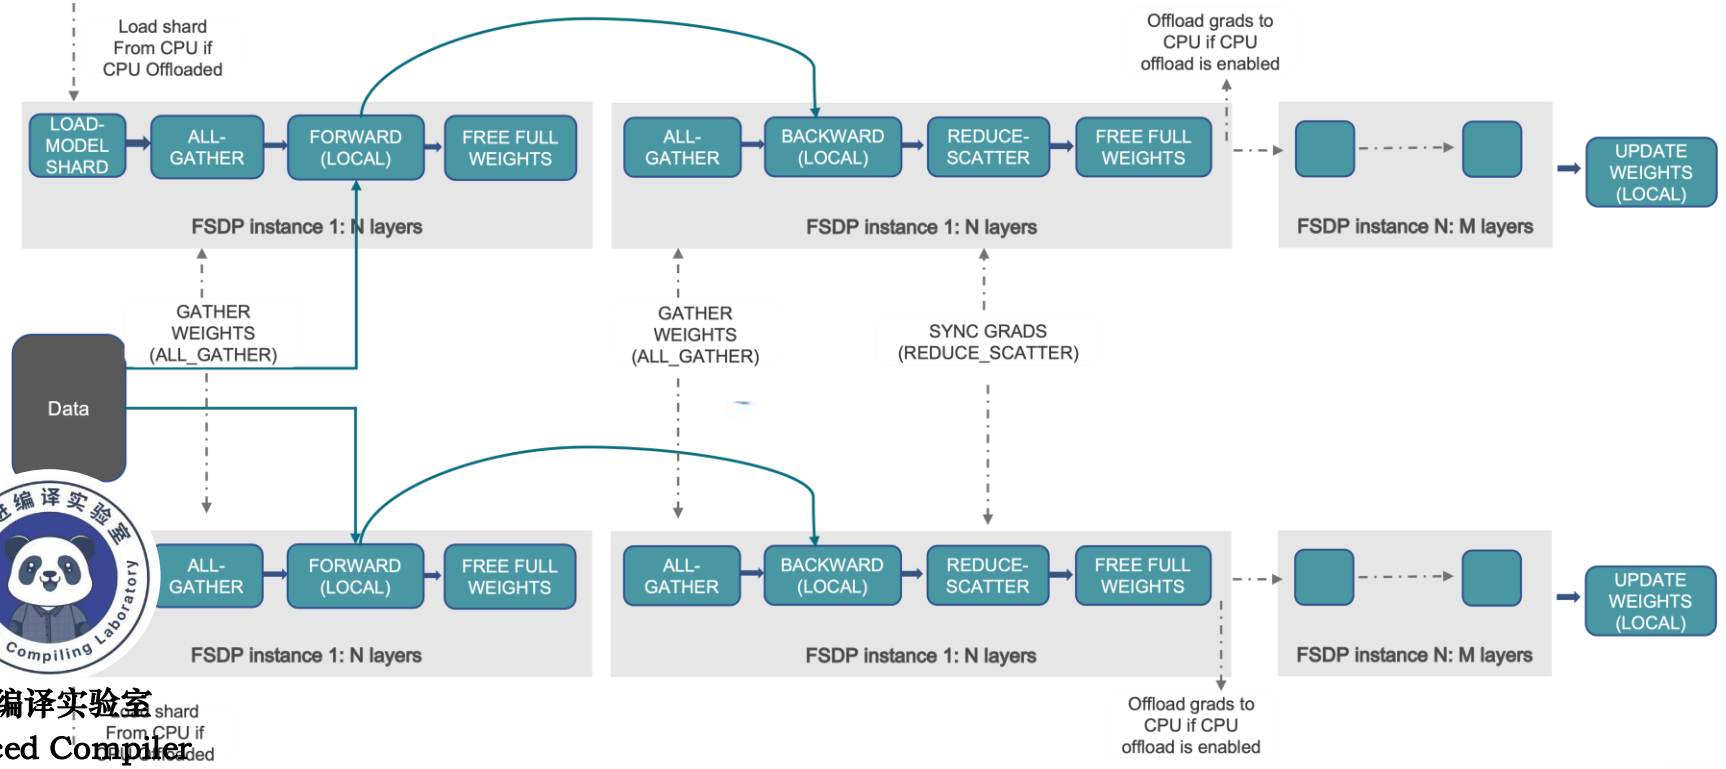

3、模型并行

解决单个训练设备的内存不足以容纳整个模型问题

将模型拆分成多个模型分片，将多个模型分片放置在不同的训练设备上

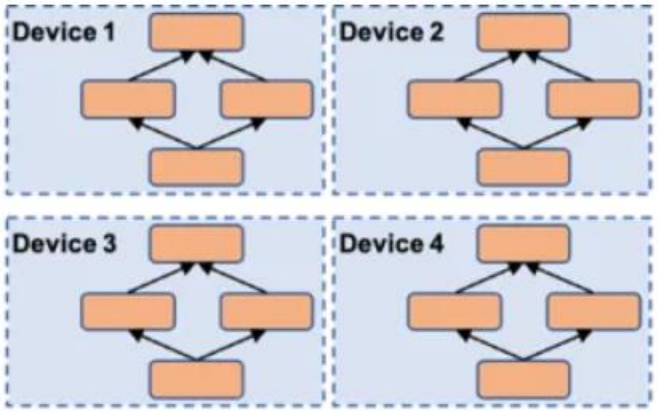

数据并行

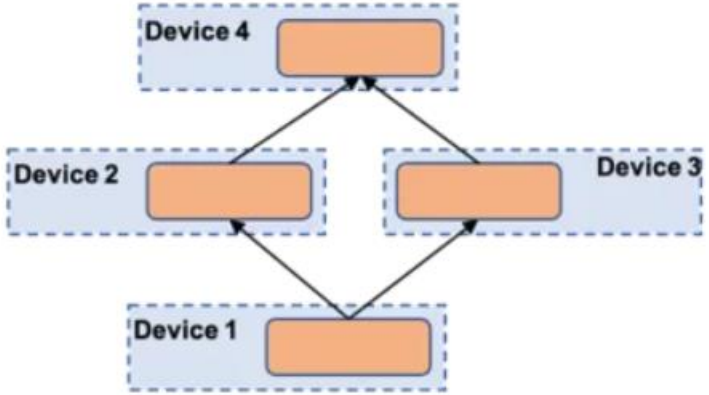

模型并行

3、模型并行

流水线并行（层间）

张量并行（层内）

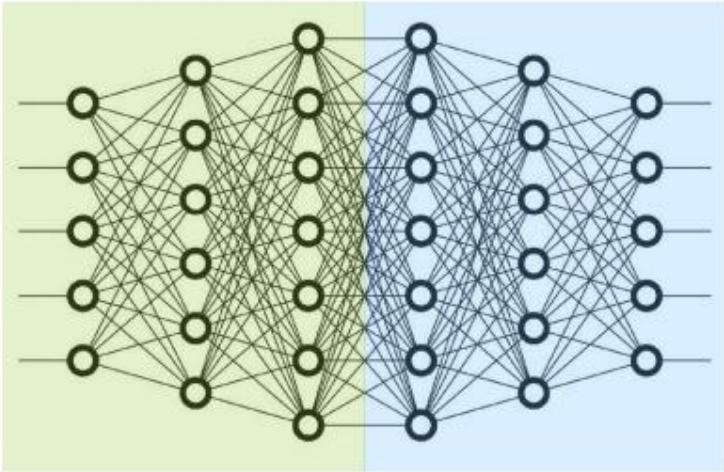

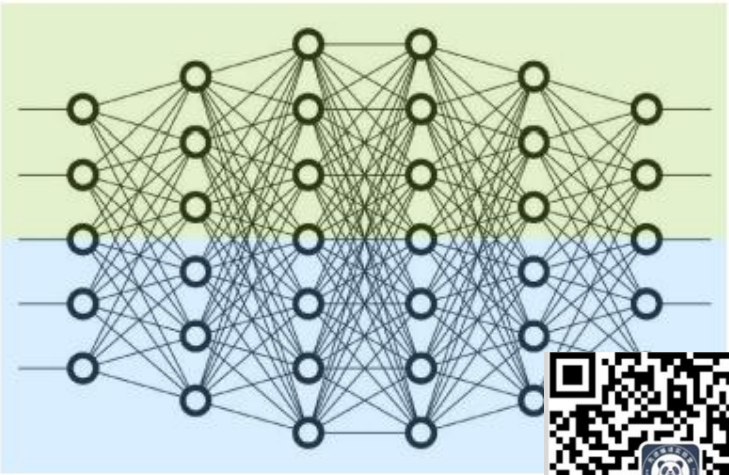

- 流水线并行是把模型不同的层放到不同设备之上。
- 张量并行则是层内分割，把某一个层做切分，放置到不同设备之上。

3.1、张量并行

$$[X] = \begin{bmatrix} X_{00} & X_{01} \\ X_{10} & X_{11} \end{bmatrix} \qquad [X] = \begin{bmatrix} X_{00} & X_{01} \\ X_{10} & X_{11} \end{bmatrix} \qquad [X] = \begin{bmatrix} X_{00} & X_{01} \\ X_{10} & X_{11} \end{bmatrix}$$

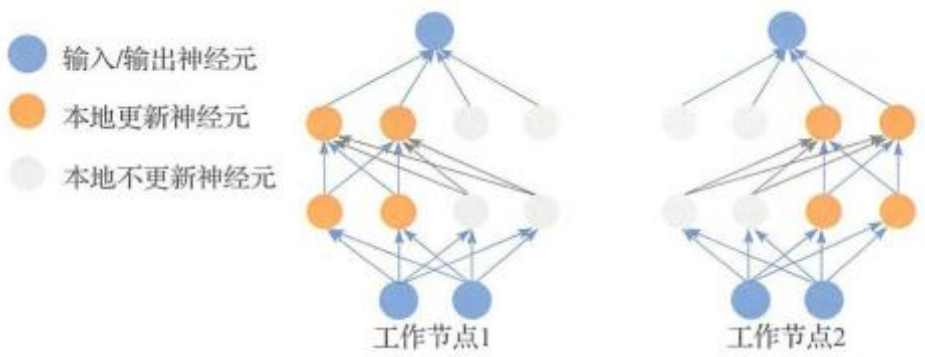

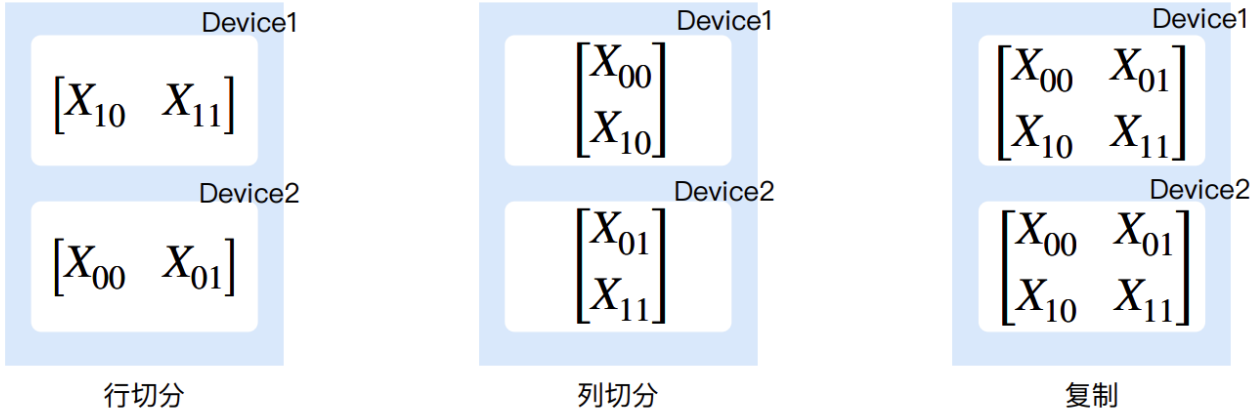

存在无法切分的层
单次通信量大，通信频繁

3.2、流水线并行

单设备只负责网络中部分层的计算

把通信和计算重叠起来以便“掩盖”通信时间

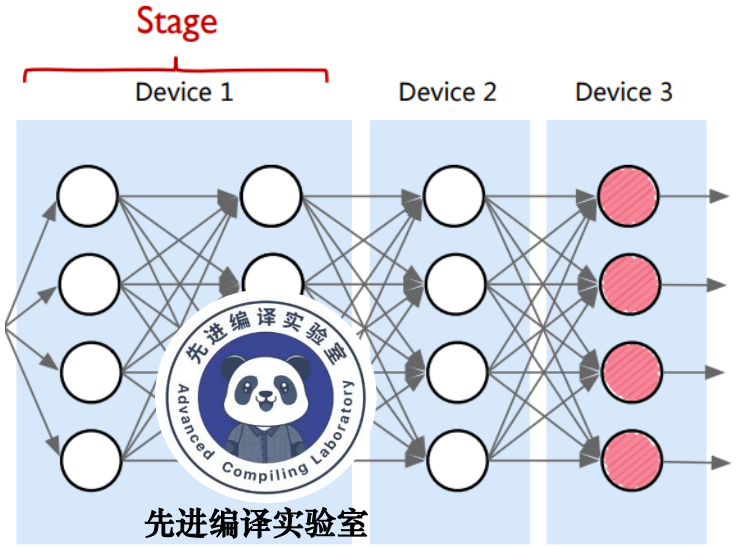

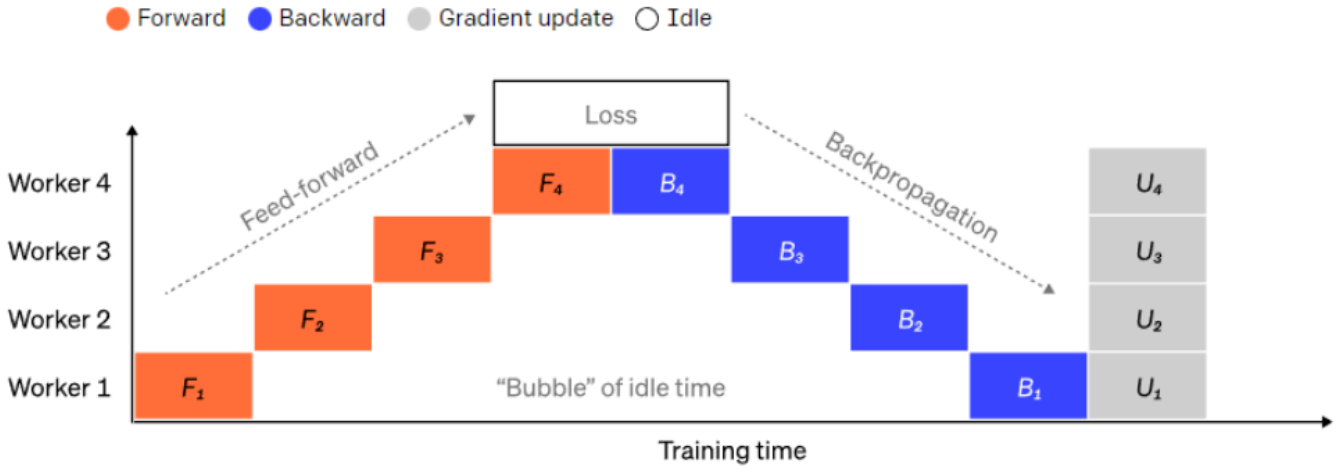

“F”、“B”和“U”分别代表前向、反向和更新操作。下标指示数据在哪个节点上运行。由于顺序依赖性，数据一次只能在一个节点上运行，从而会导致**大量空闲时间**。

3.2、流水线并行

GPipe

- 微批法
- 梯度累积
- 重计算

- 硬件利用率低
- 内存开销大

3.2、流水线并行

PipeDream

- 1F1B策略

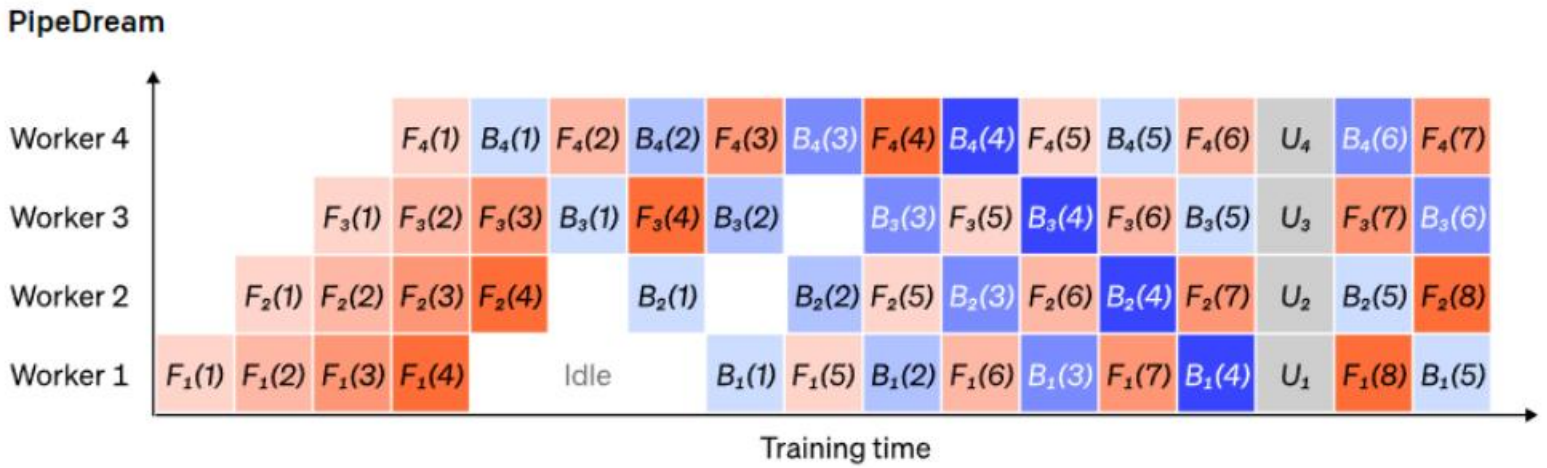

4、混合并行

简单的理解就是将数据并行和模型并行进行混合，从而达到一个更好的训练效果。

卷积层数据比参数大，适合数据并行，全连接层参数比数据大，适合模型并行。

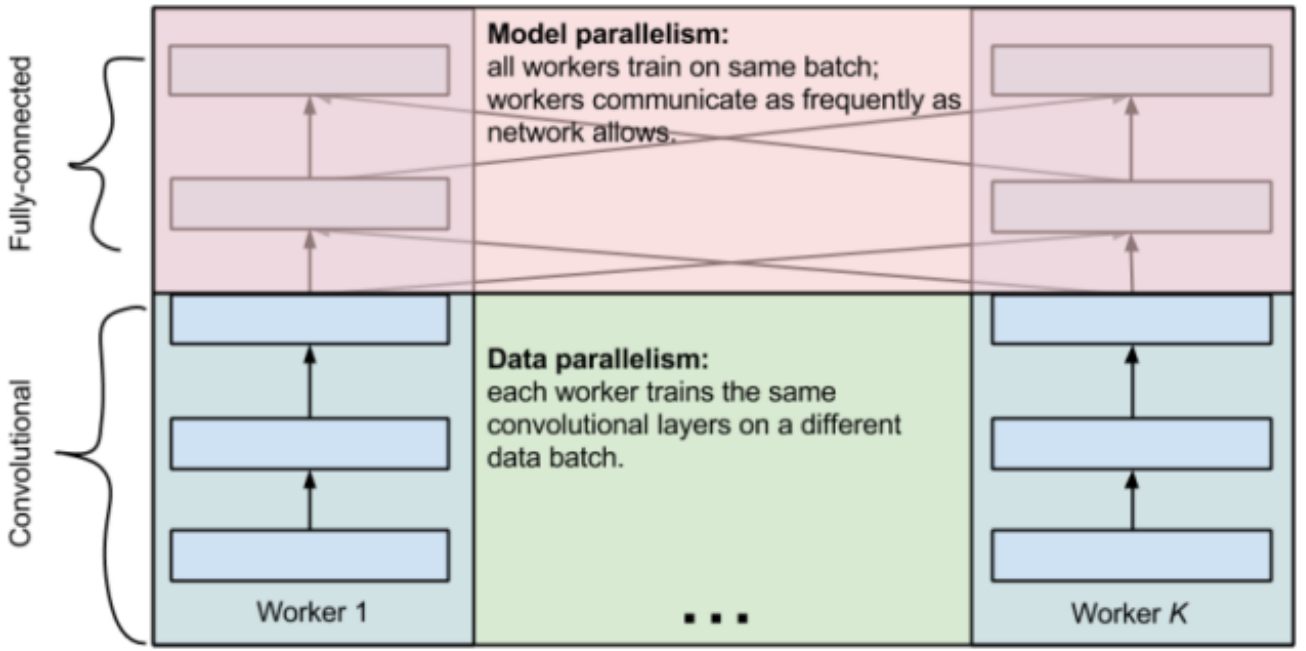

4、混合并行

以GPT-3超大模型为例

综合考虑模型特点以及硬件条件，结合数据并行和模型并行的特点，能够灵活满足训练对时间开销的需要

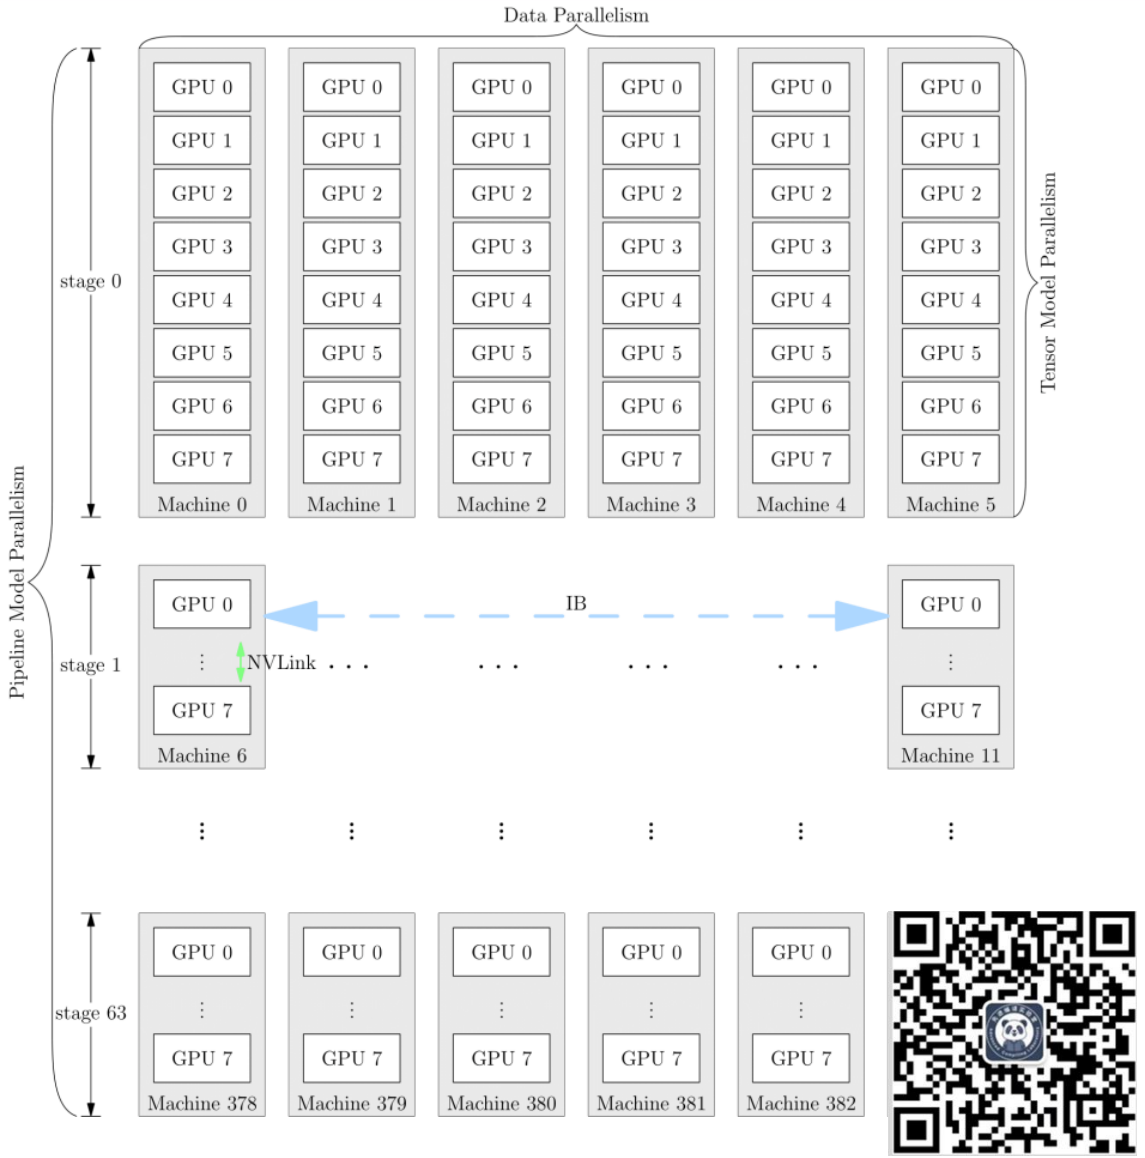

5、总结

数据并行

将数据划分到不同的设备并行训练，每个设备都有完整的网络模型。
提升训练速度，减轻单设备上计算和存储压力。

模型并行

张量并行：将模型层内划分到不同的设备并行训练。
流水线并行：将模型层间划分到不同的设备并行训练。，
解决单设备无法容纳完整模型问题。

混[illegible]行

[illegible]行+模型并行

感谢大家聆听

参考资料

分布式机器学习 算法、理论与实践

https://pytorch.org/tutorials/intermediate/FSDP_tutorial.html?highlight=fsdp

http[illegible]hihu.com/zvideo/1564591472208547841

http[illegible]blogs.com/rossiXYZ/